

Tech Challenge - Fase 01

Análise Preditiva (DATASUS)

Flamers Team

Membros da Equipe

- Flávio Oscar Hahn - RM 374132
- Larissa Gomes do Vale Cabrerisso Machado - RM 370911
- Michelle Almeida Nogueira Rodrigues - RM 372291
- Ramon Silva - RM 373445
- Selvino Wilmar Rodrigues Junior - RM 368570

1 Informações do Projeto

- **Link do Repositório Git:** [GitHub - Flamers Team](#)
- **Objetivo:** Desenvolvimento de uma arquitetura para um modelo de Machine Learning para predição de cuidados intensivos (UTI) em pacientes com doenças circulatórias.
- **Conteúdo do Repositório:** Código-fonte completo do backend (Java/Spring), scripts de análise (Python), Dockerfile para orquestração e documentação README.md.

2 Pipeline de Ciência de Dados

O notebook analiseDosDadosDATASUS.ipynb foca na classificação de risco de pacientes. O fluxo seguiu as seguintes etapas:

- **Pré-processamento:** Uso de StandardScaler para normalização de dados numéricos e OneHotEncoder para variáveis categóricas via ColumnTransformer.
- **Modelagem:** Implementação de múltiplos algoritmos:
 - Regressão Logística (Logistic Regression).
 - Árvores de Decisão (Decision Tree).
 - Florestas Aleatórias (Random Forest).
- **Tratamento de Desbalanceamento:** Aplicação de class_weight='balanced' para lidar com a menor proporção de casos de UTI no dataset.

2.1 Instruções de Execução

O projeto está configurado para rodar em ambientes isolados via Docker, garantindo a reprodutibilidade.

- **Requisitos:** Docker e Docker Compose instalados.
- **Comando de Inicialização:** docker-compose up -d --build
- **README.md:** O arquivo na raiz do repositório contém o passo a passo detalhado para configuração das variáveis de ambiente e acesso à API.

2.2 Dados e Dataset

- **Fonte:** Microdados do DATASUS (SIH - Sistema de Informações Hospitalares) de 2024.
- **Escopo:** Pacientes com doenças do aparelho circulatório (CID-10: I00 a I99).
- **Link para Download:** O dataset processado e os arquivos originais podem ser encontrados na pasta /data do repositório Git ou via este link direto.

3 Análise de Resultados e Visualizações

3.1 Estratégias de Pré-processamento

Para garantir a eficiência dos modelos de Machine Learning, as seguintes estratégias foram aplicadas:

- **Tratamento de Categóricos:** Utilização de OneHotEncoder para transformar variáveis como 'Estado' e 'Sexo' em vetores numéricos.
- **Normalização:** Aplicação de StandardScaler em variáveis numéricas (ex: Idade) para evitar que grandezas diferentes distorçam os pesos do modelo.
- **Pipeline:** Integração via ColumnTransformer para garantir que o pré-processamento aplicado ao treino seja idêntico ao de teste.

3.2 Modelos Utilizados e Justificativa

Foram testados três modelos principais para a predição de necessidade de UTI:

- **Regressão Logística:** Escolhida pela interpretabilidade e pela capacidade de gerar probabilidades (curva sigmoide), permitindo entender a "chance" percentual de UTI para cada paciente.
- **Random Forest:** Utilizado por sua robustez contra *overfitting* e por lidar bem com relações não-lineares entre as variáveis hospitalares.
- **Decision Tree:** Implementada para fornecer uma visualização clara do fluxo de decisão médica.

Com base na execução do código, os seguintes gráficos devem ser integrados ao relatório final:

3.1 Importância das Variáveis (Feature Importance)

Este gráfico (gerado na seção do Random Forest) identifica quais fatores (como idade, comorbidades ou estado) mais influenciam a decisão do modelo de enviar um paciente para a UTI.




Figura 1: Variáveis de maior peso na predição de necessidade de UTI.

3.2 Matriz de Confusão

Utilizada para avaliar a performance dos modelos de classificação, mostrando os acertos e erros (Falsos Positivos/Negativos).




Figura 2: Avaliação de performance do modelo de Regressão Logística.

4 Conclusão Analítica

O modelo de Regressão Logística apresentou uma probabilidade detalhada para cada paciente (curva sigmoide), permitindo uma triagem mais inteligente. A integração destes insights em um sistema de gestão hospitalar (ou no contexto do Tech Challenge, como uma extensão de inteligência) demonstra o valor da análise de dados do DATASUS para a saúde pública brasileira.